



CS 412 Intro. to Data Mining

Chapter 2. Getting to Know Your Data

Jiawei Han, Computer Science, Univ. Illinois at Urbana-Champaign, 2017



Data

Data

1
2
1
0
-1
1

1D

1	12	2	5
2	11	7	2
1	15	9	3
0	10	1	-3
-1	20	12	-2
1	19	6	-5

2D

1	1	12	2	5
2	2	11	7	2
1	1	15	9	3
0	0	10	1	-3
-1	-1	20	12	-2
1	1	19	6	-5

3D

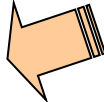
3



	Attribute 1	Attribute 2	Attribute 3	Attribute 4
Record 1	1	12	2	5
Record 2	2	11	7	2
Record 3	1	15	9	3
Record 4	0	10	1	-3
Record 5	-1	20	12	-2
Record 6	1	19	6	-5



Chapter 2. Getting to Know Your Data

- ❑ Data Objects and Attribute Types 
- ❑ Basic Statistical Descriptions of Data
- ❑ Data Visualization
- ❑ Measuring Data Similarity and Dissimilarity
- ❑ Summary

นภาพการวางที่มักความ
สัมพันธ์กัน

Types of Data Sets: (1) Record Data

- Relational records
 - Relational tables, highly structured
- Data matrix, e.g., numerical matrix, crosstabs

Ex. ตารางสินค้าขาย

	China	England	France	Japan	USA	Total
Active Outdoors Crochet Glove		12.00	4.00	1.00	240.00	257.00
Active Outdoors Lycra Glove		10.00	6.00		323.00	339.00
InFlux Crochet Glove	3.00	6.00	8.00		132.00	149.00
InFlux Lycra Glove		2.00			143.00	145.00
Triumph Pro Helmet	3.00	1.00	7.00		333.00	344.00
Triumph Vertigo Helmet		3.00	22.00		474.00	499.00
Xtreme Adult Helmet	8.00	8.00	7.00	2.00	251.00	276.00
Xtreme Youth Helmet		1.00			76.00	77.00
Total	14.00	43.00	54.00	3.00	1,972.00	2,086.00

Person:

Pers_ID	Surname	First_Name	City
0	Miller	Paul	London
1	Ortega	Alvaro	Valencia
2	Huber	Urs	Zurich
3	Blanc	Gaston	Paris
4	Bertolini	Fabrizio	Rom

Car:

Car_ID	Model	Year	Value	Pers_ID
101	Bentley	1973	100000	0
102	Rolls Royce	1965	330000	0
103	Peugeot	1993	500	3
104	Ferrari	2005	150000	4
105	Renault	1998	2000	3
106	Renault	2001	7000	3
107	Smart	1999	2000	2

- Transaction data

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Ex. ตารางเกม


	team	coach	y	pla	ball	score	game	n	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	0	2
Document 2	0	7	0	2	1	0	0	3	0	0	0
Document 3	0	1	0	0	1	2	2	0	3	0	0

- Document data: Term-frequency vector (matrix) of text documents



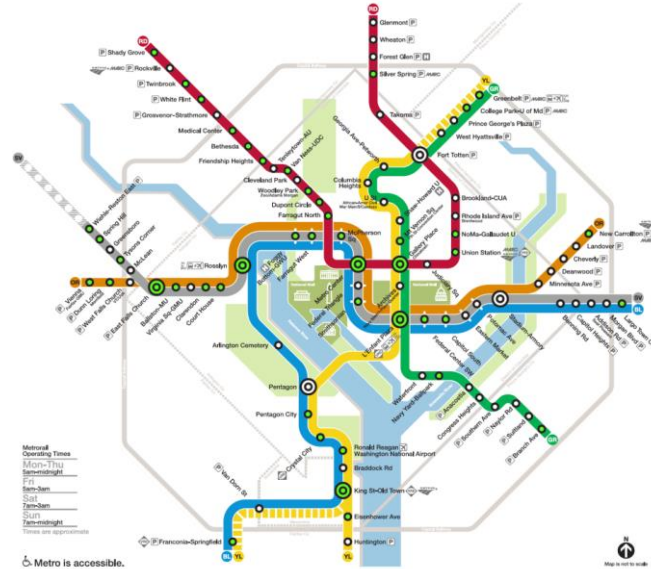
จำนวนทีม
Data 9 ไร่
แทน ข้อความ

Types of Data Sets: (2) ^{نسبة} Graphs and Networks

- ❑ Transportation network
- ❑ World Wide Web



- ❑ Molecular Structures
- ❑ Social or information networks



สำคัญ!!
ห้ามลบที่แนว


Types of Data Sets: (3) Ordered Data

→ มีความต่อเนื่อง, time series, นูน, มีลำดับชัดเจนสำคัญ

❑ Video data: sequence of images

↓
ข้อมูลต่อเนื่องตามเวลาเข้ามาเรื่อยๆ, นำมาซ้อนๆกัน (กรณีมีภาพนิ่งในสต็อก)

❑ Temporal data: time-series



❑ Sequential Data: transaction sequences

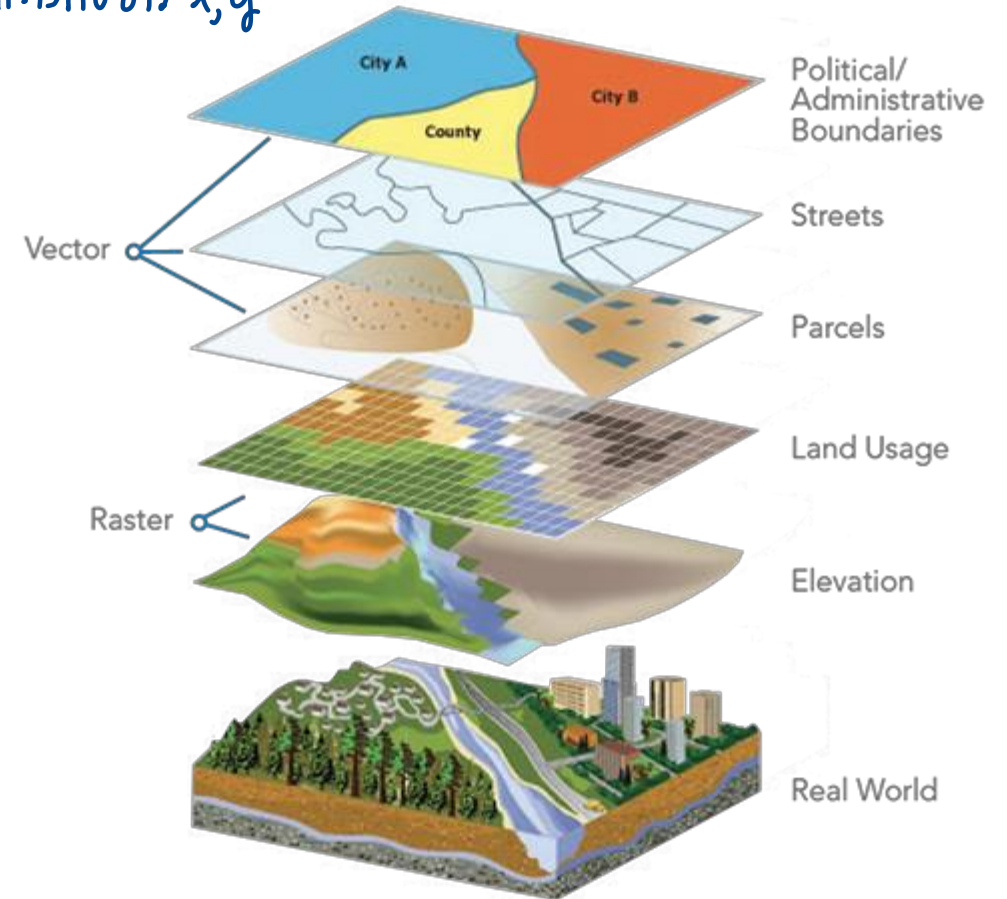
❑ Genetic sequence data

	Start
Human	GTTTGGAGG --- ATGTTCAACAAATGCTCCTTTTCATTCTCTATTTACAGACCTGCCGCA
Chimpanzee	GTTTGGAGG --- ATGTTCAATAAATGCTGCTTTTCATCTCTATTTACAGACCTGCCGCA
Macaque	GTTTGGAGG --- ATGTTCAATAAATGCTCCTTTTCATTCTCTATTTACAAACTGCCGCA
Human	GACAATTCTGCTAGCAGCCTTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Chimpanzee	GACAATTCTGCTAGCAGCCTTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Macaque	GACAATTCTGCTAGCAGCCTTTGTGCTATTATCTGTTTTCTAAACTTAGTAATTGAGTGT
Human	GATCTGGAGACTAA - CTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Chimpanzee	GATCTGGAGACTAAACTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Macaque	TATCTGGAGACTAAACTCTGAAATAAATAAGCTGATTATTTATTTATTTTCTCAAAACAA
Human	CAGAATACGATTTAGCAAAATTACTTCTTAAGATATTATTTTACATTTCTATATTCTCCTA
Chimpanzee	CAGAATACGATTTAGCAAAATTACTTCTTAAGATATTATTTTACATTTCTATATTCTCCTA
Macaque	CAGAATATGATTTAGCAAAATTACTTCTTAAGATATTATTTTGCATTTCTATATTCTCCTA
Human	CCCTGAGTTGATGTGTGAGCAATATGTCACCTTTTCATAAAGCCAGGTATACA --- TTATG
Chimpanzee	CCCTGAGTTGATGTGTGAGCCGATATGTCACCTTTTCATAAAGCCAGGTATACA --- TTATG
Macaque	CCCTGAGTTGATGTGTGAGCAATATGTCACCTTTTCATAAAGCCAGGTATATATACATTACG
Human	GACAGGTAAGTAAAAAACATATTATTATTCTACGTTTTTGTCCAAAAATTTTAAATTTT
Chimpanzee	GACAGGTAAGTAAAAAACATATTATTATTCTACGTTTTTGTCCAAAAATTTTAAATTTT
Macaque	GACAGGTAAGTAAAAAACATATTATTATTCTACGTTTTTGTCCAAAAATTTTAAATTTT
Human	AACTGTTGCGCGTGTGTTGGTAA --- TGTAAAACAAAC TCAGTACA
Chimpanzee	AACTGTTGCGCGTGTGTTGGTAA --- TGTAAAACAAAC TCAGTACA
Macaque	AACTGTTGTGCAATGTGTTGGTAA --- CBTAAAACAAATTCAGTACG

Types of Data Sets: (4) Spatial, image and multimedia Data

↓
ข้อมูลเชิงพื้นที่ที่สัมพันธ์กับพิกัด x, y

□ Spatial data: maps



□ Image data:

□ Video data: *spatio-temporal*

Important Characteristics of Structured Data

□ Dimensionality → มีมิติมากขึ้น 1, 2, 3, 4, 5

□ Curse of dimensionality

□ Sparsity → สนิทสนมที่มีข้อมูล, ข้อมูลเป็น 0 เยอะเกินไป

□ Only presence counts

□ Resolution → เก็บข้อมูลละเอียดแค่ไหน

□ Patterns depend on the scale


□ Distribution → กระจายตัวอย่างไร

□ Centrality and dispersion

Sparsity

Ex. การวัดยอดขาย

	China	England	France	Japan	USA	Total
Active Outdoors Crochet Glove		12.00	4.00	1.00	240.00	257.00
Active Outdoors Lycra Glove		10.00	6.00		323.00	339.00
InFlux Crochet Glove	3.00	6.00	8.00		132.00	149.00
InFlux Lycra Glove		2.00			143.00	145.00
Triumph Pro Helmet	3.00	1.00	7.00		333.00	344.00
Triumph Vertigo Helmet		3.00	22.00		474.00	499.00
Xtreme Adult Helmet	8.00	8.00	7.00	2.00	251.00	276.00
Xtreme Youth Helmet		1.00			76.00	77.00
Total	14.00	43.00	54.00	3.00	1,972.00	2,086.00



Data Objects

- ❑ Data sets are made up of data objects → กลุ่มของข้อมูลประกอบขึ้นมาจาก data
- ❑ A data object represents an entity → ข้อมูลแต่ละตัว
- ❑ Examples:
 - ❑ sales database: customers, store items, sales
 - ❑ medical database: patients, treatments
 - ❑ university database: students, professors, courses
- ❑ *Also called samples, examples, instances, data points, objects, tuples* → ข้อมูล
- ❑ Data objects are described by **attributes** → ข้อมูลจะถูกอธิบายด้วย attributes
- ❑ Database rows → data objects; columns → attributes

Attributes

□ Attribute (or dimensions, features, variables)

□ A data field, representing a characteristic or feature of a data object.

□ *E.g., customer_ID, name, address*

□ Types:

□ Nominal (e.g., red, blue) → ชื่อของกลุ่มข้อมูลชนิดที่ไม่ใช้ตัวเลข

□ Binary (e.g., {true, false}) → ข้อมูลมีแค่สองค่า

□ Ordinal (e.g., {freshman, sophomore, junior, senior}) → ข้อมูลเรียงลำดับ

□ Numeric: quantitative → $+$, $-$, \times , \div ได้แล้วมีค่ามากมาย

□ Interval-scaled: 100°C is interval scales

□ Ratio-scaled: 100°K is ratio scaled since it is twice as high as 50°K

□ Q1: Is student ID a nominal, ordinal, or interval-scaled data?

□ Q2: What about eye color? Or color in the color spectrum of physics?

↳ Numeric

Attribute Types

□ **Nominal**: categories, states, or “names of things”

- *Hair_color* = {auburn, black, blond, brown, grey, red, white}
- marital status, occupation, ID numbers, zip codes

□ **Binary** → เหมือน Nominal แต่มีแค่ 2 เช่น 0 กับ 1, ใช่ กับ ไม่ใช่

- Nominal attribute with only 2 states (0 and 1)
- Symmetric binary: both outcomes equally important

□ e.g., ~~gender~~, Left / Right-handed, Coke / Pepsi, Hot / Cold

□ Asymmetric binary: outcomes not equally important. → มี 2 ค่าความสำคัญไม่เท่ากัน เช่น ตรวจ covid 1 คนเป็น 2 คน ไม่ใช่เป็น 1000 คน ในหลาย

□ e.g., medical test (positive vs. negative)

□ Convention: assign 1 to most important outcome (e.g., HIV positive)

□ **Ordinal** → ไม่สามารถนำมารวมกันได้, สามารถเรียงลำดับได้

- Values have a meaningful order (ranking) but magnitude between successive values is not known
- *Size* = {small, medium, large}, grades, army rankings

Numeric Attribute Types

Quantity (integer or real-valued)

ข้อมูลที่เป็นตัวเลข
↪ มีศูนย์แท้กับไม่แท้

Interval 0 นาที เราวัดได้ 0 นาที 0 ชั่วโมง 0 วัน

- Measured on a scale of **equal-sized units**

- Values have order

 - E.g., *temperature in C° or F°, calendar dates*

- No true zero-point

Ratio

- Inherent **zero-point**


- We can speak of values as being an order of magnitude larger than the unit of measurement (10 K° is twice as high as 5 K°).

 - e.g., *temperature in Kelvin, length, counts, monetary quantities*

Discrete vs. Continuous Attributes

- ❑ **Discrete Attribute** → ระบุค่าที่วัดได้ที่มีหน่วยการวัด เช่น อายุ นามสกุล ไม่สามารถวัดค่าต่อเนื่อง
- ❑ Has only a finite or countably infinite set of values
 - ❑ E.g., zip codes, profession, or the set of words in a collection of documents
- ❑ Sometimes, represented as integer variables
- ❑ Note: **Binary** attributes are a special case of discrete attributes
- ❑ **Continuous Attribute** → วัดค่าที่ต่อเนื่องกัน เช่น สูง 180 กับ สูง 181 หรือ น้ำหนัก 180.5
- ❑ Has real numbers as attribute values
 - ❑ E.g., temperature, height, or weight
- ❑ Practically, real values can only be measured and represented using a finite number of digits
- ❑ Continuous attributes are typically represented as floating-point variables

Chapter 2. Getting to Know Your Data

- ❑ Data Objects and Attribute Types
- ❑ Basic Statistical Descriptions of Data 
- ❑ Data Visualization
- ❑ Measuring Data Similarity and Dissimilarity
- ❑ Summary

เลือกค่าทางสถิติมาใช้แสดง data ของเรานั่นคือค่าเฉลี่ย

Basic Statistical Descriptions of Data

□ Motivation

- To better understand the data: central tendency, variation and spread

เข้ขวบนจกค้กลวมากเท่าไ้

□ Data dispersion characteristics

- ^{มัชฐาน} Median, max, min, quantiles, outliers, variance, ...

แต่ค้ท้วจกค้กลวมากน้อยแค่ไ้

□ Numerical dimensions correspond to sorted intervals

- Data dispersion:


- Analyzed with multiple granularities of precision

- Boxplot or quantile analysis on sorted intervals

□ Dispersion analysis on computed measures

- Folding measures into numerical dimensions

- Boxplot or quantile analysis on the transformed cube



คนส่วนใหญ่นับว่าอายุ 20 ปี
- ฐานนิยม (ค่าเฉลี่ย)